

Detección de *Freezing of Gait* en la Enfermedad de Parkinson mediante una Red Bayesiana Dinámica

León-Altamirano F. Zarif

leon.fz@cicese.edu.mx

Center for Scientific Research and Higher Education at Ensenada (CICESE)
Ensenada, Baja California, México

ABSTRACT

El *freezing of gait* (FoG) es una interrupción repentina y breve de la marcha en la enfermedad de Parkinson que ocurre por episodios sostenidos en el tiempo. Se modela la marcha como un proceso secuencial con una Red Bayesiana Dinámica (DBN) cuyo estado oculto evoluciona como una cadena de Markov de primer orden y cuya observación se descompone en seis atributos condicionalmente independientes dado el estado, el *Freeze Index* y el *Power Index* de tres acelerómetros, con una dependencia inter-slice sobre el *Freeze Index* del tobillo que captura la inercia del FoG. Las tablas de probabilidad condicional se estiman por conteo con suavizado Laplaciano y la inferencia se realiza con Viterbi y *forward-backward*. Sobre el dataset Daphnet, se realiza una evaluación *leave-one-subject-out* contra Random Forest y SVM-RBF con los mismos features: una DBN de dos estados detecta el 0.832 de los episodios de FoG en comparación a 0.441 (RF) y 0.580 (SVM), pero con menor especificidad (0.748). Dado que el AUC es equivalente al de RF (0.853 vs 0.860), su ventaja esta en la persistencia temporal del modelo. La variante de tres estados con un estado anticipatorio pre-FoG no mejora la detección ni la anticipa de forma fiable (AUC pre-FoG 0.67).

KEYWORDS

DBN, PGM, freezing of gait, detección secuencial, LOSO

Reference Format:

León-Altamirano F. Zarif. 2026. Detección de *Freezing of Gait* en la Enfermedad de Parkinson mediante una Red Bayesiana Dinámica. In *Class of Reconocimiento de Patrones (R.P.)*. CICESE, Ensenada, BC, MX, 4 pages.

1 INTRODUCCIÓN

El *freezing of gait* (FoG) es uno de los síntomas más incapacitantes de la enfermedad de Parkinson, descrito como una interrupción breve de la marcha en la que el paciente siente que sus pies quedan pegados al suelo, siendo una de las principales causas de caídas y de deterioro de la calidad de vida [7]. Detectarlo de forma automática es necesario para sistemas de asistencia que alertan del inicio de un episodio; la acelerometría portátil ofrece una vía accesible y no invasiva para lograrlo. Así, el objetivo no es clasificar correctamente la marcha normal, abundante y fácil de detectar, sino capturar los episodios de FoG, que son escasos y clínicamente relevantes.

Un *freeze* no aparece de manera puntual sino que se establece y se sostiene durante varios instantes consecutivos, de modo que el estado de un instante es informativo sobre el siguiente. En este trabajo se aplica una Red Bayesiana Dinámica (DBN) [11], un modelo gráfico probabilista en el que un estado oculto evoluciona como una

cadena de Markov de primer orden y genera las observaciones de cada corte temporal, para modelar la marcha como un proceso secuencial y detectar el FoG. El objetivo es representar el problema y aprender los parámetros del modelo para luego realizar inferencia y evaluarlo experimentalmente bajo validación *leave-one-subject-out*, comparándolo con *baselines* de aprendizaje automático (Random Forest y SVM-RBF) que clasifican cada ventana de forma independiente. Se contrasta además una variante de tres estados que añade un estado anticipatorio pre-FoG, para medir si el modelo permite anticipar el inicio del episodio además de detectarlo.

2 TRABAJO RELACIONADO Y CONCEPTOS PREVIOS

Detección de FoG. El descriptor estándar para esta tarea es el *Freeze Index* (FI), introducido por Moore et al. [6] como el cociente entre la potencia espectral en la banda de freezing (3 a 8 Hz) y la potencia en la banda locomotora (0.5 a 3 Hz), bajo la observación de que durante un freeze la energía del movimiento se desplaza hacia frecuencias más altas. Las primeras aproximaciones aplican un umbral sobre el FI calculado en ventanas deslizantes [1, 6], lo cual es interpretable pero sensible a la elección del umbral y confunde un freeze con una parada voluntaria. Trabajos posteriores sustituyen el umbral por clasificadores supervisados sobre features espectrales [5], con buen desempeño agregado pero tratando cada ventana de manera independiente, lo que ignora la persistencia temporal del episodio. La anticipación del episodio, esto es, la identificación de un patrón motor que precede al FoG, ha sido explorada con ventanas previas de algunos segundos [8], con resultados consistentemente más débiles que la detección.

Modelos secuenciales. Un modelo oculto de Markov (HMM) representa una secuencia mediante un estado oculto con dinámica markoviana de primer orden y observaciones generadas por instante. La secuencia de estados más probable se obtiene con el algoritmo de Viterbi y las marginales posteriores $P(A_t | O)$ con *forward-backward*. Una DBN generaliza al HMM al permitir factorizar la observación en varios atributos y añadir dependencias entre cortes temporales más allá de la del estado. Cuando la observación se descompone en atributos condicionalmente independientes dado el estado, la estructura corresponde a un clasificador de red bayesiana dinámica (DBNC) [11].

3 DATOS Y CARACTERÍSTICAS

3.1 Fuente de datos

Se utiliza el dataset Daphnet *Freezing of Gait* [1], que contiene registros de diez pacientes con Parkinson capturados con tres acelerómetros triaxiales situados en el tobillo, el muslo y el tronco,

muestreados a 64 Hz, mientras realizan tareas que provocan episodios de *freezing* como marcha recta, giros y actividades de la vida diaria. Cada muestra contiene nueve ejes de aceleración (tres sitios por tres ejes, en mg) y una etiqueta: fuera del experimento (que se descarta), actividad normal o *freeze* (FoG). El FoG es una clase minoritaria y muy desigual entre sujetos, ya que algunos concentran numerosos episodios mientras que dos sujetos no presentan ninguno, lo cual condiciona tanto el protocolo de evaluación como la interpretación de las métricas.

3.2 Preprocesamiento y segmentación

Se descartan las muestras fuera del experimento y se aplica un filtro Butterworth pasa-bajas de 20 Hz de cuarto orden sobre los nueve ejes, ya que ese es el rango útil del movimiento de marcha. Al descartar las muestras fuera del experimento, la grabación queda partida en huecos, por lo que se identifican los tramos contiguos y cada uno se trata como una secuencia independiente, de modo que ninguna ventana posterior cruza un hueco. Este paso es necesario para que la dinámica markoviana del modelo no enlace instantes que en realidad no son consecutivos.

3.3 Representación de características

La señal se divide en ventanas de 3 segundos (192 muestras a 64 Hz) con un paso de 1.5 segundos, lo que corresponde a un solape del 50%, aplicado dentro de cada tramo contiguo. La duración de 3 segundos proporciona la resolución en frecuencia suficiente para separar la banda locomotora (0.5 a 3 Hz) de la banda de *freezing* (3 a 8 Hz). Por cada ventana y sensor se calcula la magnitud $\|(x, y, z)\|$ de la aceleración, que es robusta a la orientación del sensor, se le resta la media, se aplica una ventana de Hann y se obtiene su periodograma, del cual se integran dos bandas para construir dos *features* por sensor. El *Freeze Index* es el cociente $FI = P[3-8 \text{ Hz}] / P[0.5-3 \text{ Hz}]$ [6] y el *Power Index* es la potencia total $PI = P[0.5-8 \text{ Hz}]$, que se incluye porque permite distinguir un *freeze* de un reposo, dado que el FI por sí solo se vuelve inestable cuando casi no hay movimiento. Con esto, se tienen seis *features* por ventana, el FI y el PI de cada uno de los tres sensores.

3.4 Etiquetado

Se comparan dos variantes de etiquetado. Una de *dos clases* {normal, FoG} usa las etiquetas originales; la otra, de *tres clases* {normal, pre-FoG, FoG} añade un estado anticipatorio construido con una regla *pre-onset* que marca como pre-FoG las ventanas normales cuyo centro cae en el intervalo $[\text{onset} - \tau, \text{onset})$, con $\tau \in \{3, 5\}$ segundos siguiendo los rangos reportados en la literatura [8], lo que produce 363 y 524 ventanas pre-FoG respectivamente.

4 MODELO PROBABILÍSTICO

4.1 Justificación

Se elige una DBN porque modela explícitamente la dinámica del estado oculto a través de la arista de transición $A_{t-1} \rightarrow A_t$, descompone la observación en atributos condicionalmente independientes dado el estado, y permite añadir una dependencia inter-slice $O_{\text{tob},t-1}^{\text{FI}} \rightarrow O_{\text{tob},t}^{\text{FI}}$ que captura la inercia del FI de un instante al siguiente. La estructura del modelo se muestra en la Figura 1.




Figure 1: Dos cortes temporales de la DBN. El estado oculto A_t sigue una cadena de Markov de primer orden y genera las seis observaciones. El *Freeze Index* del tobillo (FI^a) depende además de su valor previo (arista discontinua); los cinco *features* restantes ($\dots$) son condicionalmente independientes dado A_t .

4.2 Formalización

El estado oculto A_t toma valores en {normal, pre-FoG, FoG} para el modelo de tres estados o en {normal, FoG} para la variante de dos estados, con cardinalidad K . En cada corte temporal la observación se descompone en seis atributos discretos, el FI y el PI de cada sensor, cada uno cuantizado en $B = 4$ bins mediante cuantiles. Dadas A_t , las seis observaciones son mutuamente independientes, salvo $O_{\text{tob}}^{\text{FI}}$, que depende adicionalmente de su valor previo. La distribución conjunta es:

$$P(A_{1:T}, O_{1:T}) = \pi(A_1) \prod_{t=2}^T P(A_t | A_{t-1}) \times \prod_{t=1}^T \left[\prod_{i \neq \text{FI}_{\text{tob}}} P(O_t^{(i)} | A_t) \right] \times \prod_t P(O_{\text{tob},t}^{\text{FI}} | A_t, O_{\text{tob},t-1}^{\text{FI}}). \quad (1)$$

Los parámetros son la distribución inicial π (K entradas), la matriz de transición A ($K \times K$), las tablas de probabilidad condicional (CPT) de los cinco *features* sin dependencia inter-slice ($K \times B$ cada una), la CPT del FI del tobillo $P(O_{\text{tob},t}^{\text{FI}} | A_t, O_{\text{tob},t-1}^{\text{FI}})$ ($K \times B \times B$) y la CPT del FI del tobillo en $t = 1$, sin valor previo ($K \times B$).

4.3 Aprendizaje de parámetros

Cada entrada de las CPT se estima por conteo con suavizado Laplaciano. Para una observación con B bins, dado el estado c ,

$$P(O^{(i)} = v | A = c) = \frac{N_{c,v}^{(i)} + 1}{N_c + B}, \quad (2)$$

donde $N_{c,v}^{(i)}$ es el número de ventanas con estado c y *feature* i en el bin v , y N_c el número de ventanas con estado c . La transición y la dependencia inter-slice se estiman de forma análoga sobre sus respectivas tablas. El suavizado garantiza que ninguna probabilidad sea cero y permite considerar combinaciones no observadas en el entrenamiento.

Los bordes de cuantiles que discretizan los seis *features* se ajustan sobre los datos de entrenamiento de cada *fold* y se aplican al sujeto de prueba, lo cual evita el problema de fuga de datos en la discretización. La elección de $B = 4$ (cuantiles) responde a la estructura del modelo y a la escasez de la clase FoG, ya que la CPT de la dependencia inter-slice tiene $K \times B \times B$ entradas, tal que un B mayor multiplica el número de parámetros a estimar y deja muy pocas

observaciones por celda, en particular para el estado FoG, lo que degrada la estimación de las tablas. Cuatro bins ofrecen resolución suficiente para los features sin comprometer la estimación de las CPT.

4.4 Inferencia

La secuencia de estados más probable, que corresponde a una tarea de decodificación, se obtiene con Viterbi en escala logarítmica,

$$\hat{A}_{1:T} = \arg \max_{A_{1:T}} P(A_{1:T} | O_{1:T}), \quad (3)$$

por programación dinámica. Las marginales posteriores por instante se obtienen con *forward-backward* en escala logarítmica,

$$P(A_t = j | O_{1:T}) = \frac{\alpha_t(j) \beta_t(j)}{\sum_i \alpha_t(i) \beta_t(i)}, \quad (4)$$

donde α_t y β_t son las cantidades *forward* y *backward*; de esta marginal se toma la componente del estado FoG como score continuo para el AUC. Ambas comparten la misma log-probabilidad de observación por instante, en la que el término del FI del tobillo se condiciona en su valor previo observado y en $t = 1$ se usa la CPT inicial.

5 EVALUACIÓN EXPERIMENTAL

5.1 Protocolo y baselines

Se utiliza *leave-one-subject-out* (LOSO): por cada sujeto de prueba se ajustan los bins y las CPT solo sobre los sujetos restantes, se decodifica el sujeto excluido del entrenamiento y se acumulan las predicciones. Este protocolo es el adecuado para esta tarea, ya que una partición que mezclara ventanas del mismo sujeto en entrenamiento y prueba produciría estimaciones optimistas que no reflejan el uso real sobre un paciente nuevo [10]. Como baselines se añaden Random Forest [2] y SVM con kernel RBF [4], ambos con ponderación de clases, que utilizan los mismos seis features continuos estandarizados por *fold* y clasifican cada ventana de forma independiente, sin modelado temporal. Se utilizan las implementaciones de *scikit-learn* [9].

5.2 Métricas

Se reporta la accuracy para comparabilidad, sin embargo, es importante notar que es engañosa debido al desbalance de clases, ya que un clasificador que prediga siempre la clase mayoritaria la maximiza sin detectar un solo freeze. Las métricas relevantes son la sensibilidad de FoG ($TP/(TP + FN)$), la fracción de ventanas de FoG detectadas y la especificidad de FoG ($TN/(TN + FP)$), la fracción de ventanas no-FoG correctamente descartadas, junto con el F1-macro, el AUC de detección y el coeficiente de correlación de Matthews (MCC). El AUC es la probabilidad de que una ventana de FoG reciba un score mayor que una ventana no-FoG tomada al azar,

$$AUC = P(s(x^+) > s(x^-)), \quad (5)$$

de modo que mide cuán bien el modelo ordena las ventanas según su verosimilitud de FoG. El MCC,

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}, \quad (6)$$

toma valores en $[-1, 1]$, es robusto al desbalance y vale cero para un clasificador trivial constante [3].

5.3 Resultados

La Tabla 1 resume las nueve configuraciones evaluadas. En la DBN de dos clases, se detecta el 0.832 de los episodios de FoG, en comparación a 0.441 de RF y 0.580 de SVM, a costa de una menor especificidad (0.748 vs 0.929 de RF). Esto se observa en la Figura 2: RF clasifica como normal más de la mitad de las ventanas de FoG reales, mientras que la DBN recupera la gran mayoría. El AUC de detección de la DBN y de RF es prácticamente idéntico (0.853 vs 0.860, Figura 3), por lo que ambos modelos ordenan igual de bien las ventanas según su verosimilitud de FoG; la diferencia en sensibilidad se debe al umbral con que cada modelo asigna la etiqueta de FoG, no a que un modelo discrimine mejor que el otro.




Figure 2: Matrices de confusión normalizadas por fila (2 clases, LOSO). La DBN recupera el 0.83 de las ventanas de FoG; RF no detecta el 0.56 de ellas a cambio de mayor especificidad sobre la clase normal.

En las otras métricas (accuracy, F1-macro, MCC), RF supera a la DBN de dos clases (F1-macro 0.675 vs 0.620), lo cual es consistente con que esas métricas valoran más acertar la clase mayoritaria. La DBN de tres clases no es mejor: la mejor variante por F1-macro ($\tau = 5$) alcanza apenas 0.411 y reduce la sensibilidad de FoG a 0.534, y el AUC del estado pre-FoG se queda en 0.668, apenas por encima del azar; sin embargo, es el único modelo que predice el estado pre-FoG de forma apreciable (Figura 4), ya que RF prácticamente nunca lo asigna, pero lo hace a costa de la detección de FoG.



6 DISCUSIÓN

La ventaja de la DBN no está en clasificar mejor sino en cómo decide, la DBN y RF ordenan las ventanas según su verosimilitud de FoG de forma equivalente (AUC 0.853 vs 0.860), de modo que ninguno separa mejor el FoG del resto; la diferencia está en cómo cada modelo asigna la etiqueta. RF asigna de forma que favorece la especificidad y clasifica como normal la mayoría de las ventanas, mientras que la DBN mantiene el estado de FoG una vez que la evidencia se acumula y lo sostiene a lo largo del episodio. Esta persistencia corresponde a la arista de transición y la dependencia inter-slice del FI del tobillo, logrando una sensibilidad de FoG que casi duplica la de RF. Esto resulta más útil en la práctica, pues no detectar un episodio es más costoso que un falso positivo.

El estado anticipatorio pre-FoG no se puede justificar, su AUC es de 0.67, y las tres clases se confunden de forma considerable, añadir el estado degradado la detección de FoG, ya que parte de la probabilidad que la variante de dos estados asignaba a FoG se reparte ahora

Table 1: Resultados LOSO sobre Daphnet. Métricas calculadas sobre las predicciones de todos los *fold*s. La accuracy y el F1-macro de las variantes de tres y dos clases no son directamente comparables (distinto número de clases), pero la sensibilidad de FoG sí.

Variante	Modelo	Acc.	F1-macro	MCC	Sens. FoG	Espec. FoG	AUC FoG	AUC pre-FoG
3 clases ($\tau = 3$)	DBN (3 estados)	0.551	0.395	0.250	0.568	0.865	0.851	0.650
3 clases ($\tau = 3$)	RF	0.844	0.474	0.370	0.571	0.902	0.865	—
3 clases ($\tau = 3$)	SVM	0.550	0.352	0.132	0.468	0.806	0.688	—
3 clases ($\tau = 5$)	DBN (3 estados)	0.549	0.411	0.264	0.534	0.886	0.851	0.668
3 clases ($\tau = 5$)	RF	0.827	0.470	0.350	0.570	0.901	0.865	—
3 clases ($\tau = 5$)	SVM	0.531	0.355	0.130	0.480	0.802	0.692	—
2 clases	DBN (2 estados)	0.756	0.620	0.368	0.832	0.748	0.853	—
2 clases	RF	0.882	0.675	0.351	0.441	0.929	0.860	—
2 clases	SVM	0.733	0.564	0.214	0.580	0.749	0.720	—

**Figure 3: ROC de detección de FoG (2 clases, LOSO). La DBN y RF son equivalentes en AUC (0.853 vs 0.860).****Figure 4: Matrices de confusión normalizadas por fila (3 clases, $\tau = 5$, LOSO).**

hacia pre-FoG. Con estos features y etiquetado, el modelo es mejor detectando el episodio que anticipándolo.

7 CONCLUSIONES

Una Red Bayesiana Dinámica con una dependencia inter-slice sobre el FI del tobillo proporciona una forma de detectar FoG que corresponde con la persistencia temporal del fenómeno. A pesar de

tener casi igual AUC que Random Forest, detecta prácticamente el doble de episodios (sensibilidad de 0.832 vs 0.441). Por otra parte, la variante de tres estados con un estado pre-FoG no mejora la detección ni lo anticipa de forma fiable, concluyéndose que el modelo es útil para detectar pero no para predecir. Como trabajo futuro podrían utilizarse dependencias inter-slice que mejor capturen el fenómeno o un modelo semi-markoviano que represente de forma explícita la duración de los estados.

REFERENCES

- [1] Marc Bachlin, Meir Plotnik, Daniel Roggen, Inbal Maidan, Jeffrey M. Hausdorff, Nir Giladi, and Gerhard Troster. 2010. Wearable Assistant for Parkinson's Disease Patients With the Freezing of Gait Symptom. *IEEE Transactions on Information Technology in Biomedicine* 14, 2 (2010), 436–446. <https://doi.org/10.1109/TITB.2009.2036165>
- [2] L. Breiman. 2001. Random Forests. *Machine Learning* 45, 1 (2001), 5–32. <https://doi.org/10.1023/A:1010933404324>
- [3] D. Chicco and G. Jurman. 2020. The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics* 21 (2020), 6. <https://doi.org/10.1186/s12864-019-6413-7>
- [4] C. Cortes and V. Vapnik. 1995. Support-vector networks. *Machine Learning* 20, 3 (1995), 273–297. <https://doi.org/10.1007/BF00994018>
- [5] Sinziana Mazilu, Michael Hardegger, Zack Zhu, Daniel Roggen, Gerhard Troester, Meir Plotnik, and Jeffrey Hausdorff. 2012. Online Detection of Freezing of Gait with Smartphones and Machine Learning Techniques. In *6th International Conference on Pervasive Computing Technologies for Healthcare*. IEEE. <https://doi.org/10.4108/icst.pervasivehealth.2012.248680>
- [6] Steven T. Moore, Hamish G. MacDougall, and William G. Ondo. 2008. Ambulatory monitoring of freezing of gait in Parkinson's disease. *Journal of Neuroscience Methods* 167, 2 (2008), 340–348. <https://doi.org/10.1016/j.jneumeth.2007.08.023>
- [7] J. G. Nutt, B. R. Bloem, N. Giladi, M. Hallett, F. B. Horak, and A. Nieuwboer. 2011. Freezing of gait: moving forward on a mysterious clinical phenomenon. *The Lancet Neurology* 10, 8 (2011), 734–744. [https://doi.org/10.1016/S1474-4422\(11\)70143-0](https://doi.org/10.1016/S1474-4422(11)70143-0)
- [8] Luca Palmerini, Laura Rocchi, Sinziana Mazilu, Eran Gazit, Jeffrey M. Hausdorff, and Lorenzo Chiari. 2017. Identification of Characteristic Motor Patterns Preceding Freezing of Gait in Parkinson's Disease Using Wearable Sensors. *Frontiers in Neurology* Volume 8 - 2017 (2017). <https://doi.org/10.3389/fneur.2017.00394>
- [9] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. 2011. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* 12, 85 (2011), 2825–2830. <http://jmlr.org/papers/v12/pedregosa11a.html>
- [10] Sohrab Saeb, Luca Lonini, Arun Jayaraman, David C. Mohr, and Konrad P. Kording. 2017. The need to approximate the use-case in clinical machine learning. *GigaScience* 6, 5 (05 2017), gix019. <https://doi.org/10.1093/gigascience/gix019>
- [11] L. E. Sucar. 2021. *Probabilistic Graphical Models: Principles and Applications* (2nd ed.). Springer, Cham. <https://doi.org/10.1007/978-3-030-61943-5>